



**universitas
MALIKUSSALEH**

**IMPLEMENTASI ALGORITMA YOLOV8 UNTUK DETEKSI
CACAT FISIK DAN KONTAMINAN PADA BIJI KOPI
SECARA *REAL-TIME***

SKRIPSI

**Disusun Sebagai Syarat Memperoleh Gelar Sarjana Komputer
Prodi Teknik Informatika Fakultas Teknik
Universitas Malikussaleh**

DISUSUN OLEH :

**NAMA : SAYID MUHAMMAD JUNDULLAH
NIM : 220170045
PRODI : TEKNIK INFORMATIKA**

**JURUSAN INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS MALIKUSSALEH
LHOKSEUMAWE**

2026

KATA PENGANTAR

Alhamdulillah penulis dapat menyelesaikan skripsi ini dengan judul **“IMPLEMENTASI ALGORITMA YOLOV8 UNTUK DETEKSI CACAT FISIK DAN KONTAMINAN PADA BIJI KOPI SECARA *REAL-TIME*”**. Skripsi ini disusun sebagai salah satu syarat dalam menyelesaikan dan memperoleh gelar Sarjana Komputer pada Program Studi Teknik Informatika Universitas Malikussaleh.

Penulis menghadapi sejumlah tantangan dan kesulitan dalam menyusun skripsi ini, namun dapat menyelesaikannya berkat nasihat, dukungan, dorongan, dan bimbingan dari berbagai pihak. Semoga Allah SWT. dapat membalas kebaikan tersebut. Oleh karena itu, penulis ingin menggunakan kesempatan ini untuk menyampaikan rasa terima kasih yang tulus kepada:

1. Bapak Prof. Dr. Ir. H. Herman Fithra, S.T., M.T., IPM., ASEAN.Eng., selaku Rektor Universitas Malikussaleh.
2. Bapak Dr. Muhammad Daud, M.T., selaku Dekan Fakultas Teknik Universitas Malikussaleh.
3. Bapak Munirul Ula, S.T., M.Eng., Ph.D selaku Ketua Jurusan Informatika Universitas Malikussaleh.
4. Bapak Hafizh Al Kautsar Aidilof, S.T., M.Kom selaku Sekretaris Jurusan Informatika Universitas Malikussaleh
5. Ibu Zara Yunizar, S.Kom., M.Kom selaku Ketua Program Studi Teknik Informatika Universitas Malikussaleh.
6. Bapak Fadlisyah, S.Si., MT selaku Dosen Pembimbing Utama yang banyak membantu dalam memberikan arahan dan nasihat yang berguna dalam penyusunan skripsi ini.

7. Bapak Hafizh Al Kautsar Aidilof, S.T., M.Kom selaku Dosen Pembimbing Pendamping yang banyak membantu dalam memberikan arahan dan nasihat yang berguna dalam penyusunan skripsi ini.
8. Bapak Arnawan Hasibuan, S.T., M.T., Ph.D. selaku penguji satu dan bapak Dr. Eng., Defry Hamdhana, S.T., M.Eng. selaku dosen penguji dua.
9. Kedua orang tua Penulis, Bapak Said Fakhrudin dan Ibu Asnita yang selalu mendukung, dan berdoa yang tidak ada henti agar anaknya bisa menyelesaikan masa studinya sampai sarjana, serta menjadi segalanya dalam hidup penulis karena tanpa mereka penulis bukanlah siapa- siapa.
10. Ibu dan Bapak Dosen dan seluruh Staf Jurusan Informatika, Fakultas Teknik Universitas Malikussaleh yang telah memberikan ilmu pengetahuan dan membantu penulis dalam segala hal selama di bangku perkuliahan.

Penulis menyadari masih banyak kekurangan dan kelemahan dalam penyusunan laporan ini, maka penulis dengan tulus menerima saran dan kritik yang membangun. Akhir kata, penulis mengucapkan terima kasih dan berharap semoga karya ini bermanfaat bagi semua pihak.

Lhokseumawe, 23 Oktober 2025

Penulis,

Sayid Muhammad Judullah

NIM. 220170045

DAFTAR ISI

KATA PENGANTAR.....	ii
DAFTAR ISI.....	iv
DAFTAR TABEL	vi
DAFTAR GAMBAR.....	vii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian.....	6
1.4 Batasan Masalah.....	6
1.5 Manfaat Penelitian.....	7
BAB II TINJAUAN PUSTAKA.....	9
2.1 DP Kopi atau Double Picker	9
2.2 Karakteristik Biji Kopi dan Kontaminan.....	9
2.2.1 Standar Penilaian Mutu Fisik.....	11
2.3 Deep Learning.....	13
2.3.1 CNN (<i>Convolutional Neural Network</i>)	13
2.3.2 <i>Object Detection</i>	14
2.3.3 Perbandingan Model: Faster R-CNN, SSD dan YOLO ..	16
2.4 Arsitektur dan Performa YOLOv8	16
2.4.1 <i>Mean Average Precision</i> (mAP)	18
2.5 Penelitian Terdahulu	18
BAB III METODE PENELITIAN.....	25
3.1 Tempat Dan Waktu	25
3.2 Skema Penelitian	25
3.3 Analisis Kebutuhan Sistem	27
3.3.1 Analisa Kebutuhan Perangkat Keras (<i>Hardware</i>).....	27
3.3.2 Analisa Kebutuhan Perangkat Lunak (<i>Software</i>)	29
3.4 Skema Sistem.....	30
3.4.1 Logika Perhitungan Skor Nilai Cacat Otomatis	33

BAB IV HASIL DAN PEMBAHASAN	35
4.1 Hasil Penelitian	35
4.1.1 Visualisasi Dataset	35
4.1.2 Pembagian Dataset	36
4.2 <i>Preprocessing</i> dan Augmentasi Data	61
4.2.1 <i>Resize</i> dan Normalisasi	61
4.2.2 Anotasi (Labeling)	61
4.2.3 Augmentasi Data	61
4.3 Pelatihan Model (<i>Training</i>)	62
4.3.1 Konfigurasi Model	62
4.3.2 Hasil Pelatihan	62
4.4 Evaluasi Model	62
4.4.1 <i>Confusion Matrix</i>	63
4.4.2 <i>Performance Metrics</i>	64
4.5 Implementasi Sistem dan Skenario Pengguna	67
4.5.1 Antarmuka Sistem	67
4.5.2 Skenario 1: Deteksi <i>Real-Time</i>	69
4.5.3 Skenario 2: Deteksi Gambar Statis/Batch	70
4.5.4 Aksesibilitas Mobile	70
4.5.1 Panduan Operasional Sistem	72
4.5.2 Evaluasi Pengguna	75
BAB V KESIMPULAN DAN SARAN	76
5.1 Kesimpulan	76
DAFTAR PUSTAKA	79

DAFTAR TABEL

Table 2.1 Klasifikasi Mutu Biji Kopi SNI 01-2907-2008.....	12
Table 2.2 Klasifikasi Mutu Berdasarkan Sistem Nilai Cacat.....	13
Tabel 2.3 Penelitian Terdahulu	19
Table 4.1 Matriks Performa model	66

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur CNN	14
Gambar 2. 2 Pendekatan Utama dalam Object Detection.....	15
Gambar 2. 3 Arsitektur YOLOv8	17
Gambar 2. 4 Mean Average Precision (mAP).....	18
Gambar 3. 1 Skema Penelitian.....	25
Gambar 3. 2 Skema Sistem	30
Gambar 4. 1 Biji Berjamur (Moldy Bean)	36
Gambar 4. 2 Biji Berkulit Ari	37
Gambar 4. 3 Biji Berkulit Tanduk.....	38
Gambar 4. 4 Biji Berlubang Lebih dari Satu	39
Gambar 4. 5 Biji Berlubang Satu	40
Gambar 4. 6 Biji Bertutul.....	41
Gambar 4. 7 Biji Cokelat (Chocolate Finish).....	42
Gambar 4. 8 Biji Hitam Pecah	43
Gambar 4. 9 Biji Hitam Penuh.....	44
Gambar 4. 10 Biji Hitam Sebagian	45
Gambar 4. 11 Biji Muda.....	46
Gambar 4. 12 Biji Pecah	47
Gambar 4. 13 Biji Brown Yellow (Sour Bean).....	48
Gambar 4. 14 Biji Normal.....	49
Gambar 4. 15 Kopi Gelondong	50
Gambar 4. 16 Kulit Kopi Ukuran Besar	51
Gambar 4. 17 Kulit Kopi Ukuran Kecil	52
Gambar 4. 18 Kulit Kopi Ukuran Sedang.....	53
Gambar 4. 19 Kulit Tanduk Ukuran Besar	54
Gambar 4. 20 Kulit Tanduk Ukuran Kecil.....	55
Gambar 4. 21 Kulit Tanduk Ukuran Sedang.....	56
Gambar 4. 22 Ranting Ukuran Besar	57
Gambar 4. 23 Ranting Ukuran Kecil.....	58
Gambar 4. 24 Ranting Ukuran Sedang	59

Gambar 4. 25 Kerikil.....	60
Gambar 4. 26 Anotasi Data.....	61
Gambar 4. 27 Grafik Pelatihan Model	62
Gambar 4. 28 Confussion Matrix.....	64

BAB I

PENDAHULUAN

1.1 Latar Belakang

Kopi merupakan salah satu komoditas perkebunan yang memiliki prospek bagus di Indonesia serta memiliki nilai ekonomi besar di pasar global. Menurut Kementerian Pertanian untuk 2022-2025, Indonesia adalah produsen kopi terbesar keempat di dunia setelah Brazil, Vietnam, dan Kolombia, dengan produksi sekitar 789.000 ton per tahun. Ekspor bersih diperkirakan meningkat dari 420.000 ton pada 2024 menjadi 427.000 ton pada 2025. Sementara konsumsi domestik turun dari 368.000 ton menjadi 361.000 ton. Pada Januari-September 2024, ekspor kopi mencapai 342.000 ton atau senilai 1,49 miliar dollar AS (Rp 23 triliun), dengan tujuan utama ke Amerika Serikat, Mesir, Jerman, dan Malaysia (www.kompas.com, 2025).

Kualitas biji kopi menjadi faktor penentu dalam memenuhi standar ekspor dan menjaga reputasi kopi Indonesia di tingkat internasional. Dalam industri kopi, biji yang cacat secara fisik, seperti biji pecah, hitam, atau berlubang, serta adanya kontaminan asing seperti batu, ranting, atau logam, dapat menurunkan kualitas secara signifikan. Cacat dan kontaminan tersebut tidak hanya memengaruhi cita rasa dan aroma kopi tetapi juga berpotensi menimbulkan risiko kesehatan bagi konsumen. Oleh karena itu, proses sortasi biji kopi menjadi tahap kritis dalam produksi untuk memastikan hanya biji berkualitas tinggi yang dipasarkan.

Standar mutu internasional yang ditetapkan *International Coffee Organization* (ICO) mensyaratkan toleransi cacat fisik dan kontaminan tidak melebihi 5%. Biji kopi yang mengandung cacat atau terkontaminasi, serangga, dan logam akan mengalami penurunan nilai jual yang signifikan dikarenakan kualitas kopi yang menentukan nilai jual, daya saing, serta kepuasan konsumen internasional, bahkan produk berisiko ditolak oleh pasar

ekspor. Hal ini berdampak langsung pada pendapatan petani dan industri kopi nasional (Ainnur Rizal, 2019).

Saat ini proses sortasi tradisional atau di sebut juga dengan *double picker* biasanya dilakukan yang oleh petani langsung atau pekerja khusus untuk pemilahan kopi mana saja yang masuk dan melewati standar kulaitas untuk di jual (Sirappa et al., 2024). Namun proses ini masih mengandalkan pengelihanatan manusia sehingga memiliki beberapa kelemahan seperti cara sorting tiap pekerja yang menyebabkan inkonsistensi kualitas antar produksi dan pastinya lebih memakan waktu dan mengeluarkan biaya untuk membayar pekerja pemilah kopi.

Selain itu, ketika pembeli kopi dalam skala besar ingin memastikan kualitas kopi, dilakukan pengecekan secara manual juga dengan cara memilah biji satu persatu dari sampel kopi yang telah ditentukan sesuai standarnya. Pengambilan sampel kopi hijau, terutama untuk pengujian cacat, dilakukan dalam jumlah terbatas; contohnya, Angola menggunakan sampel 600g untuk mengklasifikasi kopi ke dalam 11 jenis berdasarkan jumlah cacat, Kolombia menggunakan 500g dengan batas maksimum 72 cacat, Gabon menggunakan 300g untuk menentukan kualitas seperti Supérieur atau Courant, dan Rwanda menggunakan 350g untuk analisis fisik dan organoleptik (*cupping*) (Council, 2018). Namun dalam penelitian ini fokusnya hanya untuk analisis deteksi secara fisik saja. Di Indonesia sendiri, proses verifikasi kualitas oleh pembeli (buyer) mengacu pada Standar Nasional Indonesia (SNI) 01-2907-2008. Dalam standar ini, penentuan mutu dilakukan melalui pengambilan sampel sebanyak 300 gram dengan syarat kadar air maksimal 12,5%. Prosedur ini menjadi filter utama dalam transaksi perdagangan kopi untuk menentukan klasifikasi mutu fisik sebelum biji kopi didistribusikan lebih lanjut.

Perkembangan *deep learning* khususnya algoritma YOLO (*You Only Look Once*) menawarkan terobosan signifikan. YOLOv8 mampu memproses citra dengan akurasi multidimensi dalam mengenali fitur spasio-kontekstual seperti tekstur, bentuk, dan pola warna. Pada penelitian sebelumnya implementasi model YOLOv8 di industri tekstil berhasil

mendeteksi cacat kain dengan precision 82,88% dan recall 84,32% (Alam et al., 2025). Pada sistem deteksi jenis sampah menggunakan YOLOv8 ini mencapai akurasi 88% (Suwela & Hedriyadi, 2025). Keunggulan adaptabilitas model ini terhadap variasi pencahayaan dan latar belakang yang beragam menjadikannya ideal untuk aplikasi sortasi biji kopi.

Penerapan YOLOv8 pada biji kopi ini memiliki tantangan dalam penentuan jenis kecacatan fisik kopi, terdapat biji dengan ketidaksempurnaan seperti pecah, rusak, berlubang, muda (*imperfection beans*) dan kotoran atau benda asing (*impurities*) yang harus diidentifikasi. Perbedaan visual antar cacat seringkali sangat halus, seperti pada kasus *light sour* dan *underripe* yang hanya memiliki selisih warna yang halus. Ukuran biji kopi yang kecil (5–10 mm) juga memerlukan resolusi kamera tinggi dan teknik augmentasi spesifik. Faktor lingkungan seperti debu dan getaran mesin juga berpotensi menurunkan akurasi.

Berdasarkan analisis teknologi model ini, peneliti akan melakukan *fine-tuning* YOLOv8 untuk sistem sortasi biji kopi dengan tiga inovasi utama: Pertama, peningkatan akurasi deteksi melalui *transfer learning* dari model *pretrained* COCO ke dataset khusus berisi 2000 citra biji kopi yang di-annotasi sesuai standar *International Coffee Organization* (ICO). Kedua, pengembangan arsitektur *lightweight* berbasis YOLOv8n untuk bertujuan mencapai latensi inferensi yang rendah (di bawah 50 ms per biji) pada perangkat komputasi edge seperti Jetson Nano atau Raspberry Pi. Ketiga, implementasi teknik augmentasi data dan *fine-tuning hyperparameter* untuk meningkatkan generalisasi model pada variasi biji kopi. Diharapkan, model yang di *fine tuning* ini mampu mencapai akurasi deteksi yang tinggi pada dataset uji, dengan potensi signifikan dalam meningkatkan kecepatan dalam mengetahui nilai cacat pada sampel biji kopi.

Urgensi penerapan teknologi otomatis dalam mendeteksi nilai cacat pada sampel biji kopi ini semakin relevan jika ditinjau dari perspektif pengelolaan pasca panen di sentra produksi lokal, seperti di Aceh. Sebagaimana dijelaskan oleh Kembaren dan Muchsin (2021) dalam

penelitian mereka mengenai pengelolaan kopi Arabika Gayo, tahapan pasca panen merupakan fase yang sangat krusial karena hasil akhir dari proses ini secara langsung menentukan nilai tambah (added value) dan harga jual komoditas di pasar (Kembaren & Muchsin, 2021). Dalam konteks ini, manajemen mutu tidak hanya berhenti pada budidaya, tetapi sangat bergantung pada konsistensi penanganan fisik biji kopi setelah dipanen. Kembaren dan Muchsin menekankan bahwa standar pengujian biji kopi, baik secara fisik maupun organoleptik yang mengacu pada SNI dan standar SCAA (*Specialty Coffee Association of America*), menuntut ketelitian tinggi, di mana keberadaan biji cacat atau benda asing (kontaminan) harus diminimalisir secara ketat untuk menjaga kualitas. Namun, proses penyortiran manual yang umum dilakukan oleh petani maupun kolektor seringkali memiliki keterbatasan dalam hal kecepatan dan konsistensi, sehingga intervensi teknologi menjadi solusi yang tak terelakkan untuk mempertahankan standar mutu tersebut secara efisien (Kembaren & Muchsin, 2021).

Di sisi lain, pemilihan algoritma YOLO (*You Only Look Once*) dalam penelitian ini didasarkan pada rekam jejak keberhasilannya yang telah teruji dalam berbagai implementasi computer vision, termasuk dalam penelitian yang dilakukan di lingkungan Universitas Malikussaleh. Munandar, Yunizar, dan Retno (2024) telah membuktikan keandalan algoritma ini melalui pengembangan sistem deteksi abjad Bahasa Isyarat Indonesia (BISINDO) (Munandar et al., 2024). Dalam penelitian tersebut, algoritma YOLO terbukti mampu bekerja sangat efektif sebagai model deteksi objek berbasis deep learning yang cepat dan efisien. Hasil evaluasi dari penelitian Munandar dkk. menunjukkan bahwa model YOLO mampu mencapai performa yang sangat baik dengan Mean Average Precision (mAP) sebesar 87,1% serta mampu membedakan kelas objek dengan akurasi tinggi (Munandar et al., 2024).

Lebih jauh lagi, implementasi yang dilakukan oleh Munandar dkk. menegaskan kemampuan YOLO dalam melakukan deteksi secara real-time dengan konsistensi yang tinggi, yang mana merupakan aspek vital untuk aplikasi praktis yang memfasilitasi komunikasi langsung (Munandar et al., 2024). Keberhasilan penerapan YOLO dalam mendeteksi gestur tangan yang kompleks dan bervariasi tersebut memberikan landasan empiris yang kuat bahwa arsitektur ini juga memiliki kapabilitas yang mumpuni untuk diterapkan pada deteksi cacat fisik biji kopi. Jika algoritma ini mampu mengenali pola gestur tangan yang dinamis dengan presisi tinggi, maka adaptasi model untuk mengenali fitur statis seperti tekstur, warna, dan bentuk pada biji kopi diharapkan dapat memberikan hasil akurasi yang setara atau bahkan lebih baik. Oleh karena itu, integrasi wawasan mengenai pentingnya nilai tambah pasca panen dari penelitian Kembaren dan Muchsin, yang dipadukan dengan bukti keandalan teknis algoritma YOLO dari penelitian Munandar dkk., menjadi dasar argumentasi yang kokoh dalam pengembangan sistem deteksi cacat biji kopi otomatis ini.

Meskipun algoritma YOLOv8 mendukung deteksi secara real-time melalui aliran video, implementasi pada penelitian ini mempertimbangkan keterbatasan praktis seperti latensi jaringan, keterbatasan spesifikasi server, serta kestabilan frame rate yang hanya berkisar antara 5–10 FPS pada pengujian berbasis web. Selain itu, proses penilaian mutu biji kopi berdasarkan nilai cacat tidak ideal dilakukan secara real-time karena membutuhkan akurasi deteksi yang tinggi pada setiap objek. Oleh karena itu, pendekatan yang digunakan dalam penelitian ini adalah deteksi berbasis citra statis (image-based detection), di mana pengambilan data dilakukan dalam bentuk foto untuk memastikan kualitas visual yang lebih stabil, sehingga perhitungan nilai cacat dan klasifikasi mutu dapat dilakukan secara lebih akurat dan konsisten.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang diuraikan di atas, maka permasalahan yang penulis rumuskan adalah :

1. Bagaimana melatih (fine-tuning) model YOLOv8 agar mampu mendeteksi biji kopi beserta jenis cacat fisiknya secara otomatis dan akurat sesuai standar ICO dan SNI?
2. Bagaimana merancang dan mengembangkan sistem deteksi nilai cacat pada sampel biji kopi berbasis web yang terintegrasi dengan model YOLOv8 sehingga proses identifikasi cacat biji kopi dapat dilakukan secara instan?

1.3 Tujuan Penelitian

Berdasarkan latar belakang dan rumusan masalah di atas, maka tujuan penelitian ini adalah sebagai berikut:

1. Mengembangkan dan melakukan fine-tuning model YOLOv8 pada dataset biji kopi yang telah di-annotasi sesuai standar ICO dan SNI untuk mendeteksi cacat fisik dan kontaminan.
2. Membangun sistem identifikasi dan klasifikasi kualitas biji kopi berbasis web yang terintegrasi dengan model YOLOv8 untuk mendeteksi cacat fisik dan kontaminan serta menghitung nilai cacat secara otomatis berdasarkan citra statis, sehingga proses evaluasi mutu dapat dilakukan secara lebih akurat dan konsisten.

1.4 Batasan Masalah

Batasan masalah yang ditetapkan pada penelitian ini adalah sebagai berikut:

1. Penelitian ini hanya mendeteksi cacat fisik dan kontaminan pada biji kopi secara visual (makroskopis) dengan klasifikasi multi-kelas, yaitu: biji normal, biji berlubang, biji hitam, biji pecah, dan kontaminan yang terlihat dengan mata (misalnya batu atau kotoran lain). Penelitian ini tidak membahas cacat mikroskopis maupun cacat kimiawi.

2. Data citra yang digunakan berupa citra RGB berukuran 640×640 piksel, diambil dari satu kamera dengan posisi top-down (dari atas). Biji kopi disusun satu lapis (tidak saling menumpuk). Pencahayaan yang digunakan adalah cahaya alami atau lampu LED dengan intensitas sekitar 3000–6000 lux. Parameter kamera dibuat konstan selama pengambilan data. Pengujian model dilakukan hanya pada kondisi pencahayaan alami dan LED tersebut.
3. Proses inferensi model dilakukan secara near real-time pada laptop, tanpa menggunakan teknik optimasi hardware khusus. Penelitian ini tidak membahas analisis konsumsi daya, performa termal, deteksi kontaminan mikroskopis/kimiawi, serta pengaruh kondisi pabrik sesungguhnya seperti getaran mesin dan debu.
4. Sistem mendukung deteksi berbasis video (real-time) dengan keterbatasan frame rate sekitar 5–10 FPS tergantung kondisi jaringan dan server, namun proses evaluasi mutu dan perhitungan nilai cacat dilakukan menggunakan citra statis untuk memastikan akurasi deteksi yang optimal.
5. Evaluasi kinerja model dilakukan menggunakan metrik mAP@0.5, baik per kelas maupun rata-rata.

1.5 Manfaat Penelitian

Adapun Manfaat dari penelitian ini adalah sebagai berikut :

1. Sistem yang dikembangkan diharapkan mampu mendeteksi biji kopi normal dan cacat secara otomatis dengan tingkat akurasi yang tinggi, sehingga dapat meminimalkan kesalahan, sehingga biji bagus tidak ikut terbuang dan biji cacat tidak lolos. Proses grading jadi lebih cepat dibanding manual.

2. Kebutuhan tenaga kerja manual berkurang dan kerja ulang karena salah sortir menurun, sehingga biaya produksi bisa lebih hemat dan alat lebih cepat balik modal.
3. Hasil sortiran lebih konsisten sesuai standar ICO dan SNI, tingkat penolakan dari pembeli turun, dan reputasi mutu kopi meningkat sehingga lebih mudah masuk pasar ekspor.
4. Sistem dapat berjalan secara praktis di perangkat seperti smartphone atau laptop, sehingga cocok untuk industri kopi skala kecil hingga menengah.

BAB II

TINJAUAN PUSTAKA

2.1 DP Kopi atau *Double Picker*

DP Kopi atau *Double Picker* merupakan istilah yang sering digunakan dalam pengolahan kopi, khususnya di Kota Takengon, Aceh Tengah. Proses *Double Picker* ini merupakan tahapan penting dalam proses pengolahan kopi Gayo, biasanya *double picker* dilakukan setelah proses pengeringan kurang lebih selama 5 hingga 7 hari agar kadar air dalam biji kopi dari 45%-50% sehingga menjadi 18% - 20% (Nafisah et al., 2023). Proses DP yang dilakukan di tempat pengolahan kopi di Takengon dilakukan secara manual oleh beberapa orang untuk memisahkan antara kopi yang tidak memenuhi standar dan kopi memenuhi standar untuk dijual. Kopi yang cacat, berlubang, memiliki warna yang tidak biasa atau pecah bahkan ada ranting atau benda lain yang masuk ke dalam kumpulan kopi saat proses penjemuran, akan di pisahkan dan tidak akan di masukkan ke tahap selanjutnya.

2.2 Karakteristik Biji Kopi dan Kontaminan

Standar internasional yang ditetapkan oleh *International Coffee Organization* (ICO) mengklasifikasikan biji kopi berdasarkan jenis cacat dan kontaminan yang dapat menurunkan kualitasnya. Klasifikasi ini sangat penting untuk memastikan biji kopi memenuhi standar mutu yang diperlukan untuk perdagangan global. Penggolongan ini membantu produsen, pedagang, dan pembeli menilai kualitas biji kopi secara seragam.

1. **Kopi Hitam Penuh** Biji kopi yang seluruh permukaan bagian luarnya berwarna hitam pekat. Karakteristik ini biasanya disebabkan oleh fermentasi yang berlebihan, buah yang terlalu matang dan jatuh ke tanah, atau serangan jamur saat pengeringan yang lambat.

2. **Biji Kopi Hitam Sebagian** Biji kopi yang hanya sebagian permukaannya berwarna hitam (kurang dari setengah bagian). Pada pengolahan kering, hal ini sering dipicu oleh pengeringan buah yang tidak merata di lantai jemur.
3. **Biji Kopi Hitam Pecah** Biji kopi yang sudah mengalami perubahan warna menjadi hitam dan kondisinya hancur atau terbelah. Kerusakan ini menunjukkan kombinasi kegagalan fisiologis (hitam) dan kegagalan mekanis saat proses pengupasan.
4. **Biji Berwarna Cokelat** (*Chocolate Finish*) Biji yang memiliki warna cokelat tua hingga cokelat kemerahan. Karakteristik ini sering ditemukan pada kopi yang dipetik dalam keadaan lewat matang atau akibat suhu pengeringan yang terlalu panas pada buah utuh.
5. **Biji Muda** Biji kopi yang memiliki bentuk keriput, berukuran lebih kecil dari rata-rata, dan biasanya berwarna agak kehijauan pucat. Hal ini terjadi karena biji dipetik saat buah masih berwarna hijau (belum matang sempurna) sehingga sel-sel biji belum terbentuk penuh.
6. **Biji Berlubang Satu** Biji yang memiliki satu lubang kecil yang menembus permukaan. Lubang ini merupakan tanda serangan hama serangga bubuk kopi (*Hypothenemus hampei*) saat buah masih di pohon atau saat penjemuran.
7. **Biji Berlubang Lebih Dari Satu** Biji kopi yang memiliki dua lubang atau lebih akibat serangan hama serangga. Tingginya jumlah lubang menunjukkan tingkat kerusakan jaringan biji yang lebih parah yang dapat merusak cita rasa kopi.
8. **Biji Pecah** Biji kopi yang hancur atau terpotong namun warnanya masih normal (tidak hitam). Kerusakan ini murni bersifat mekanis, biasanya akibat tekanan mesin pengupas (*huller*) yang tidak pas atau kadar air biji yang terlalu rendah saat diproses.
9. **Biji Bertutul** Biji kopi yang permukaannya memiliki bintik-bintik kecil berwarna cokelat atau gelap. Bercak ini biasanya merupakan bekas serangan serangga pengisap atau infeksi jamur permukaan yang tidak sampai menghitamkan seluruh biji.

10. **Kopi Gelondong** Buah kopi kering yang masih utuh lengkap dengan kulit luar, daging buah, dan kulit tanduknya. Keberadaan gelondongan dalam sampel menunjukkan proses pengupasan kulit (*hulling*) yang tidak sempurna.
11. **Biji Kopi Berkulit Tanduk** Biji kopi yang masih terbungkus oleh lapisan kulit dalam yang keras (endokarp). Kulit tanduk ini seharusnya sudah terlepas sepenuhnya saat proses pembersihan mekanis.
12. **Kulit Kopi Ukuran Besar** Potongan kulit luar kopi (eksokarp) yang kering dengan ukuran lebih dari 10 mm. Ini merupakan residu dari proses pengolahan kering yang tidak terpisah secara baik.
13. **Kulit Kopi Ukuran Sedang** Potongan kulit luar kopi yang kering dengan ukuran antara 5 mm hingga 10 mm yang ikut tercampur dalam biji bersih.
14. **Kulit Kopi Ukuran Kecil** Serpihan kulit luar kopi yang kecil (kurang dari 5 mm). Meski kecil, keberadaannya tetap dihitung sebagai pengotor fisik.
15. **Kulit Tanduk Ukuran Besar** Serpihan kulit dalam (endokarp) yang berwarna kuning gading dengan ukuran besar (lebih dari 10 mm) yang terlepas dari biji namun belum tersaring.
16. **Kulit Tanduk Ukuran Sedang** Serpihan kulit dalam kopi dengan dimensi antara 5 mm hingga 10 mm.
17. **Kulit Tanduk Ukuran Kecil** Serpihan tipis dari kulit dalam kopi yang berukuran kurang dari 5 mm.
18. **Batu, Ranting atau Tanah Berukuran Besar** Material asing non-kopi yang memiliki ukuran lebih besar dari rata-rata biji kopi (biasanya > 10 mm). Benda ini sangat berisiko merusak mesin penyangrai dan penggiling.
19. **Batu, Ranting atau Tanah Berukuran Sedang** Material asing yang memiliki ukuran hampir setara dengan satu butir biji kopi.
20. **Batu, Ranting atau Tanah Berukuran Kecil** Material asing berukuran kecil (seperti kerikil atau potongan ranting kecil) yang sering kali sulit dibedakan dengan biji kopi jika tidak diperiksa secara teliti.

2.2.1 Standar Penilaian Mutu Fisik

Dalam industri kopi, kualitas fisik biji tidak hanya dinilai dari keberadaan cacat, tetapi juga dihitung berdasarkan bobot atau nilai cacat (defect score). Hal ini merujuk pada pedoman uji fisik seperti Standar Nasional Indonesia (SNI) maupun *International Coffee Organization* (ICO), di mana pengujian Test Defect dilakukan untuk menghitung jumlah nilai cacat pada sampel kopi guna menentukan grade atau kelas mutu. Berdasarkan standar tersebut, setiap jenis cacat fisik dan kontaminan memiliki bobot penalti yang berbeda-beda, tergantung pada seberapa parah dampaknya terhadap kualitas akhir kopi. Tabel berikut menunjukkan sistem penilaian cacat yang digunakan sebagai acuan penentuan mutu fisik biji kopi:

Table 2.1 Klasifikasi Mutu Biji Kopi SNI 01-2907-2008

No	Jenis Cacat (Indonesia/English)	Nilai Cacat
1	Biji hitam / Black bean	1 (satu)
2	Biji hitam sebagian / Partly black bean	1/2 (setengah)
3	Biji hitam pecah / Broken black bean	1/2 (setengah)
4	Kopi gelondong / Husk coffee	1 (satu)
5	Biji coklat / Brown bean	1/4 (seperempat)
6	Kulit kopi (husk) ukuran besar / Large husk fragment	1 (satu)
7	Kulit kopi (husk) ukuran sedang / Medium husk fragment	1/2 (setengah)
8	Kulit kopi (husk) ukuran kecil / Small husk fragment	1/5 (seperlima)
9	Biji berkulit tanduk / Bean in fragment	1/2 (setengah)
10	Kulit tanduk ukuran besar / Large parchment fragment	1/2 (setengah)
11	Kulit tanduk ukuran sedang / Medium parchment fragment	1/5 (seperlima)
12	Kulit tanduk ukuran kecil / Small parchment fragment	1/10 (sepersepuluh)
13	Biji pecah / Broken bean	1/5 (seperlima)
14	Biji muda / Immature bean	1/5 (seperlima)
15	Biji berlubang satu / Bean with one hole	1/10 (sepersepuluh)

16	Biji berlubang lebih dari satu / Bean with more than one hole	1/5 (seperlima)
17	Biji bertutul-tutul (proses basah) / Spotted bean	1/10 (sepersepuluh)
18	Ranting, tanah, atau batu ukuran besar / Large stick/stone	5 (lima)
19	Ranting, tanah, atau batu ukuran sedang / Medium stick/stone	2 (dua)
20	Ranting, tanah, atau batu ukuran kecil / Small stick/stone	1 (satu)


Table 2.2 Klasifikasi Mutu Berdasarkan Sistem Nilai Cacat

M u t u	Jumlah Nilai Cacat
Mutu 1	Maksimum 11
Mutu 2	12 sampai dengan 25
Mutu 3	26 sampai dengan 44
Mutu 4a *)	45 sampai dengan 60
Mutu 4b *)	61 sampai dengan 80
Mutu 5	81 sampai dengan 150
Mutu 6	151 sampai dengan 225

2.3 Deep Learning

2.3.1 CNN (Convolutional Neural Network)

Convolutional Neural Network (CNN) merupakan arsitektur *deep learning* yang dirancang khusus untuk pemrosesan data visual. Ini adalah metode khusus dalam *Machine Learning* yang menggunakan jaringan saraf (*neural networks*) dalam lapisan-lapisan berurutan untuk belajar dari data secara iteratif (Satya et al., 2023). CNN sangat efektif dalam mengolah data gambar dan tugas-tugas *Computer Vision*, dan algoritma seperti YOLO dikategorikan sebagai algoritma CNN (Ariatmanto, Aris Setiyadi, Ema Utami, 2023).




Gambar 2. 1 Arsitektur CNN
(Sumber: <https://miro.medium.com>)

CNN digunakan untuk memproses input gambar, mengidentifikasi fitur atau objek penting dalam gambar untuk keperluan pembelajaran mesin, serta membedakan berbagai jenis gambar. Model ini memungkinkan mesin untuk memahami, menganalisis, dan mengontrol proses produksi dalam konteks Revolusi Industri 4.0 CNN mengekstraksi fitur hirarkis dari gambar, seperti tepi, tekstur, dan pola kompleks, melalui operasi penyaringan (*filtering*) dan pengumpulan (*pooling*). Lapisan-lapisan ini memungkinkan CNN belajar representasi gambar secara otomatis tanpa memerlukan ekstraksi fitur manual.

2.3.2 Object Detection

Deteksi objek (*object detection*) adalah tugas untuk mengidentifikasi dan melokalisasi objek dalam gambar dengan *bounding box* dan klasifikasi. Berbeda dengan klasifikasi gambar biasa, deteksi objek harus menangani multiple objects dan variasi skala/posisi. Dua pendekatan utama adalah:



Gambar 2. 2 Pendekatan Utama dalam Object Detection
(Sumber: <https://www.researchgate.net>)

a) Two-Stage Detectors

Contoh Penerapan *Two-Stage Detectors* ini digunakan pada model Faster R-CNN dimana tahapannya yakni;

Tahap 1: Proposal wilayah (*Region Proposal Network*).

Tahap 2: Klasifikasi dan regresi *bounding box*.

Pendekatan ini cukup Akurat namun lambat karena beratnya komputasi.

b) One-Stage Detectors

Untuk pendekatan *One-Stage Detectors* seperti model YOLO dan SSD, keunggulannya terletak pada kecepatan. Model ini secara langsung memprediksi *bounding box* dan kelas dalam satu tahap, menjadikannya pilihan ideal untuk deteksi cacat fisik dan kontaminan pada biji kopi karena kecepatannya dalam mendeteksi.

Kecepatan model dalam mendeteksi objek ini sangat penting dikarenakan memungkinkan otomatisasi *quality control* (QC) secara *real-time* pada volume biji yang besar. Dengan YOLO, sistem dapat dengan cepat mengidentifikasi berbagai jenis cacat—mulai dari biji yang tidak sempurna hingga kontaminan asing—sehingga proses penyortiran dapat dilakukan dengan efisien dan akurat.

2.3.3 Perbandingan Model: Faster R-CNN, SSD dan YOLO

Berdasarkan penelitian sebelumnya dalam perbandingan model deteksi objek untuk identifikasi sudut molar ketiga pada radiograf panoramik gigi oleh Vilcapoma et al. (2024), ketiga model deteksi objek—Faster R-CNN, SSD, dan YOLO V2—menunjukkan performa yang berbeda tergantung pada arsitektur ekstraksi fitur (ResNet-18, ResNet-50, ResNet-101) dan konfigurasi *hyperparameter* yang digunakan (Vilcapoma et al., 2024).

YOLO V2 terbukti menjadi model dengan efektivitas tertinggi dalam masalah deteksi sudut molar ketiga, mencapai performa akurasi rata-rata (mean *average accuracy*) hingga 99% pada dataset pengujian (Vilcapoma et al., 2024). Keunggulan ini konsisten di berbagai arsitektur ResNet yang digunakan sebagai feature extractor, dengan akurasi pengujian mencapai 96% untuk ResNet-18 dan 99% untuk ResNet-101 (Vilcapoma et al., 2024). YOLO V2 melakukan deteksi objek sebagai masalah regresi tunggal, secara langsung memprediksi *bounding box* dan probabilitas kelas dalam satu evaluasi, sehingga tidak memerlukan jaringan *Region Proposal Network* (RPN) seperti Faster R-CNN. Pendekatan *single-stage* ini berkontribusi pada kecepatan inferensinya yang tinggi.


Keunggulan algoritma YOLO dalam mendeteksi objek secara real-time juga telah dibuktikan di lingkungan Universitas Malikussaleh. Penelitian oleh Gunawan Nurdin dan Fajriana (2022) berhasil merancang prototipe sistem deteksi objek menggunakan YOLOv3 yang mampu bekerja secara real-time, menunjukkan bahwa pendekatan one-stage detector sangat potensial untuk diaplikasikan pada sistem sortasi berbasis citra seperti deteksi cacat biji kopi (Rizka Gunawan & Fajriana, n.d.).

2.4 Arsitektur dan Performa YOLOv8

YOLOv8 adalah model yang dikembangkan oleh Ultralytics dan resmi diluncurkan pada Januari 2023 (Satya et al., 2023). Algoritma YOLO termasuk dalam kategori *Deep Learning* dan menggunakan jaringan saraf

untuk membagi citra masukan ke dalam grid untuk pengenalan citra, deteksi *bounding box*, dan probabilitas (Ariatmanto, Aris Setiyadi, Ema Utami, 2023). Model ini telah dikenal karena akurasi yang tinggi dan ukuran model yang kecil (Satya et al., 2023).

YOLOv8 berfokus pada penerapan arsitektur *You Only Look Once* (YOLOv8) untuk mendeteksi objek. Arsitektur YOLOv8 secara umum memiliki tiga bagian utama: *Backbone*, *Neck*, dan *Head* (Ariatmanto, Aris Setiyadi, Ema Utami, 2023).



Gambar 2. 3 Arsitektur YOLOv8
(sumber: <https://www-mdpi-com>)

- Backbone*: Berfungsi sebagai langkah awal untuk melakukan ekstraksi fitur (*feature extraction*) dari gambar input, menghasilkan peta fitur (*feature maps*).
- Neck*: Menghubungkan *Backbone* dengan *Head*, bertanggung jawab memproses peta fitur agar lebih berguna untuk deteksi objek. Struktur *Neck* dapat menghasilkan peta fitur multi-

skala, yang penting untuk mendeteksi objek dengan berbagai ukuran.

- c) *Head*: Bagian yang bertanggung jawab untuk melakukan deteksi dan klasifikasi objek berdasarkan peta fitur dari *Neck*, menghasilkan prediksi kotak pembatas (*bounding boxes*), skor kepercayaan (*confidence scores*), dan klasifikasi objek (Alif et al., 2024).

2.4.1 Mean Average Precision (mAP)

Metrik mAP adalah metrik evaluasi tunggal yang merangkum kinerja model deteksi objek secara keseluruhan, dihitung dengan mengambil rata-rata dari Average Precision (AP) di seluruh kelas objek yang ada; metrik ini secara efektif mengukur kualitas prediksi dengan mengintegrasikan Precision dan Recall pada semua ambang batas *Confidence Score* model, di mana penentuan *True Positive* (TP) diwajibkan melewati ambang batas *Intersection over Union* (IoU) yang telah ditetapkan (seperti 0.5 atau dirata-ratakan dari 0.5 hingga 0.95), sehingga memastikan bahwa deteksi yang dianggap benar tidak hanya memiliki kelas yang tepat tetapi juga lokasi spasial *bounding box* yang akurat.

Rumus matematis untuk mAP adalah:

$$mAP = \frac{1}{k} \sum_i^k AP_i$$

Gambar 2. 4 Mean Average Precission (mAP)
(sumber: <https://www.superannotate.com>)

2.5 Penelitian Terdahulu

Penelitian sebelumnya adalah salah satu acuan dalam melakukan suatu penelitian yang dapat memberikan wawasan kepada penulis serta

menyempurnakan teori dalam menilai penelitian yang sedang dilakukan penelitian. Adapun penelitian terdahulu yang dijadikan referensi adalah sebagai berikut :

Tabel 2.3 Penelitian Terdahulu

NO	NAMA PENELITI	JUDUL PENELITIAN	HASIL PENELITIAN
1.	Rahmawati et al. (2021)	Deteksi Defect Coffee Pada Citra Tunggal Green Beans Menggunakan Metode Ensemble Decision Tree	Penelitian ini fokus pada deteksi cacat biji kopi hijau menggunakan metode Ensamble Decision Tree.

Tabel 2.1 Penelitian Terdahulu (Lanjutan)

	Perbedaan dengan Penelitian Ini		
	Menggunakan metode <i>Ensemble Decision Tree</i> yang berbeda dengan YOLOv8 yang akan digunakan pada penelitian ini.		
2.	Aryo Michael & Juprianus Rusman (2023)	Klasifikasi Cacat Biji Kopi Menggunakan Metode Transfer Learning dengan <i>Hyperparameter</i> Tuning Gridsearch	Mengklasifikasikan cacat biji kopi menggunakan transfer learning dengan model MobileNetV2 dan DenseNet201, di mana DenseNet201 mencapai akurasi 93%.
	Perbedaan dengan Penelitian Ini		
	Meskipun pada objek yang sama (biji kopi cacat), penelitian ini menggunakan pendekatan <i>transfer learning</i> dengan CNN untuk klasifikasi, sementara penelitian penulis berfokus pada deteksi objek menggunakan YOLOv8.		
3.	Juprianus Rusman et al. (2023)	Prototype Sistem Penyortir Buah Kopi Arabika Berdasarkan Tingkat Kematangan Menggunakan Metode Support Vector Machine	Sortasi buah kopi Arabika berdasarkan tingkat kematangan (mentah, setengah matang, matang) menggunakan <i>Support Vector Machine</i> (SVM), mencapai akurasi 86,67%.
	Perbedaan dengan Penelitian Ini		
	Penelitian ini berfokus pada tingkat kematangan buah kopi (bukan biji) dan menggunakan metode SVM, berbeda dengan fokus deteksi cacat dan kontaminan biji kopi menggunakan YOLOv8.		

Tabel 2.1 Penelitian Terdahulu (Lanjutan)

NO	NAMA PENELITI	JUDUL PENELITIAN	HASIL PENELITIAN
4.	Bramastya Wisnu Pratama et al. (2022)	Rancang Bangun Mesin Sortir Biji Kopi Dengan Metode <i>FLC</i> Berbasis <i>Mikrokontroller</i> Dan <i>Computer Vision</i>	Mensortir biji kopi berdasarkan ukuran (kecil, sedang, besar) menggunakan <i>Computer Vision</i> dan <i>Fuzzy Logic Control (FLC)</i> . Akurasi FLC 98,46% dan tingkat keberhasilan sortasi 95,464%.
		Perbedaan dengan Penelitian Ini	
		Penelitian ini fokus pada sortasi ukuran biji kopi dan menggunakan metode <i>FLC</i> , bukan deteksi cacat dan kontaminan biji kopi menggunakan YOLOv8.	
5.	Irwan Adhi Prasetya et al. (2024)	Klasifikasi Kualitas Buah Jeruk Menggunakan <i>Computer Vision</i> dengan Arsitektur YOLOv8	Mengklasifikasikan kualitas buah jeruk (matang, belum matang, busuk) menggunakan YOLOv8. Mencapai akurasi 96,89%, mAP@0.5 0,993, presisi 0,98, recall 0,97, dan F1-score 0,99.
		Perbedaan dengan Penelitian Ini	
		Meskipun menggunakan arsitektur YOLOv8, objek yang dideteksi dan diklasifikasi adalah buah jeruk dan kualitasnya, bukan biji kopi, cacat, atau kontaminan	

Tabel 2.1 Penelitian Terdahulu (Lanjutan)

NO	NAMA PENELITI	JUDUL PENELITIAN	HASIL PENELITIAN
6.	Fadli Amman Siwaka et al. (2025)	Implementasi Algoritma <i>Deep Learning</i> YOLOv8 pada Alat Sortir Kematangan Buah Tomat	Mensortir kematangan buah tomat (mentah, setengah matang, matang, busuk) menggunakan YOLOv8. Mencapai akurasi total 0,99.
	Perbedaan dengan Penelitian Ini		
	Penelitian ini mengimplementasikan YOLOv8 untuk sortasi kematangan buah tomat, yang berbeda dengan fokus penelitian penulis pada deteksi cacat dan kontaminan biji kopi.		
7.	Lejar Satya et al. (2023)	Sistem Pendeteksi Plat Nomor Polisi Kendaraan dengan Arsitektur YOLOv8.	Menerapkan YOLOv8 untuk mendeteksi plat nomor polisi kendaraan secara otomatis, dengan presisi 0,871 dan recall 0,85.
	Perbedaan dengan Penelitian Ini		
	Penelitian ini menerapkan YOLOv8 untuk deteksi plat nomor kendaraan, yang merupakan domain dan objek yang berbeda dibandingkan deteksi cacat biji kopi.		

Tabel 2.1 Penelitian Terdahulu (Lanjutan)

NO	NAMA PENELITI	JUDUL PENELITIAN	HASIL PENELITIAN
8.	Muhammad Alif Amri Muzammil & Rarasmaya Indraswari (2024)	Pengembangan Arsitektur Model YOLOv8 untuk Meningkatkan Performa <i>Object Detection</i> pada Varian <i>Boks Warehouse Palletizing</i>	Mengembangkan modifikasi arsitektur YOLOv8 untuk deteksi varian boks paletisasi gudang, mencapai mAP 95,6% dan kecepatan inferensi 12ms.
	Perbedaan dengan Penelitian Ini		
	Penelitian ini fokus pada optimalisasi arsitektur YOLOv8 untuk deteksi objek boks pada paletisasi gudang, yang berbeda dengan objek dan jenis cacat yang diteliti pada biji kopi.		

Pada penelitian ini, telah dilakukan tinjauan terhadap berbagai studi sebelumnya yang menerapkan *computer vision* dan *deep learning* untuk sortasi produk pertanian dan deteksi objek. Penelitian terdahulu telah berhasil mengklasifikasikan cacat biji kopi menggunakan metode seperti *transfer learning* dengan MobileNetV2 dan DenseNet201, mencapai akurasi hingga 93% (Michael et al., 2023). Aplikasi YOLO juga sukses digunakan untuk deteksi kualitas pada komoditas lain seperti cabai rawit, buah jeruk, dan kematangan tomat (Siwaka et al., 2025).

Meskipun demikian, penelitian-penelitian sebelumnya belum secara komprehensif mengatasi tantangan spesifik dalam deteksi cacat fisik dan kontaminan pada biji kopi. Tantangan ini diperparah oleh perbedaan visual yang sangat halus antar cacat (<5% selisih warna RGB) dan ukuran biji kopi

yang kecil (5-10 mm). Oleh karena itu, penelitian ini menawarkan pendekatan yang lebih canggih dengan berfokus pada *fine tuning* YOLOv8 untuk sistem deteksi cacat biji kopi. Ini melibatkan peningkatan akurasi melalui transfer learning dari model *pretrained* COCO ke dataset khusus biji kopi yang lebih representatif, implementasi augmentasi data dan *fine-tuning hyperparameter*. Pendekatan ini diharapkan dapat menghasilkan akurasi deteksi yang tinggi dan efisien.


BAB III

METODE PENELITIAN

3.1 Tempat Dan Waktu

Penelitian ini akan dilaksanakan di tempat tinggal penulis, yaitu Takengon, Kec. Kebayakan, Kab. Aceh Tengah. Perencanaan dan pelaksanaan penelitian dijadwalkan untuk dimulai pada bulan Juni 2025 sampai selesai. Seluruh tahapan penelitian akan dilakukan secara luring, dengan proses pengambilan dataset yang berlokasi di rumah peneliti.

3.2 Skema Penelitian



Gambar 3. 1 Skema Penelitian

Skema penelitian ini dirancang untuk mencakup seluruh spektrum siklus penelitian, dari perumusan masalah hingga perumusan kesimpulan yang komprehensif.

1. Pengumpulan Data: Tahap awal melibatkan pengumpulan sebanyak 2.000 citra objek biji kopi yang akan menjadi dataset utama dalam penelitian ini. Kualitas dan kuantitas data pada tahap ini sangat krusial untuk kinerja model.
2. Praprocessing Data: Setelah data terkumpul, serangkaian langkah pra-pemrosesan dilakukan untuk mempersiapkan data agar sesuai untuk pelatihan model. Ini mencakup pengubahan ukuran gambar (resize) untuk menyeragamkan dimensi, normalisasi data untuk menstandarisasi skala piksel, penerapan augmentasi data untuk memperkaya dataset dan meningkatkan robustnes model, serta anotasi data atau pelabelan untuk memberikan informasi lokasi dan identitas objek biji kopi dalam citra. Tahap ini diakhiri dengan pembagian dataset menjadi data training, validation, dan testing, yang esensial untuk melatih, menyetel, dan mengevaluasi model secara objektif.
3. Pembangunan & Pelatihan Model: Pada tahap ini, arsitektur model YOLOv8 disiapkan untuk proses pelatihan. Pendekatan transfer learning dari model YOLOv8 dimanfaatkan, yang memungkinkan pemanfaatan bobot pra-terlatih dari dataset yang lebih besar, sehingga mempercepat konvergensi dan meningkatkan akurasi. Selain itu, penentuan dan implementasi hyperparameter tuning dilakukan untuk mengoptimalkan kinerja model dengan menyesuaikan parameter internal seperti learning rate, batch size, dan lainnya.
4. Pengujian dan Evaluasi Model: Setelah model dilatih, performanya diuji menggunakan data uji yang terpisah, yang belum pernah dilihat oleh model selama pelatihan. Kemudian,

kinerja model dievaluasi secara komprehensif menggunakan metrik-metrik yang relevan untuk objektif deteksi objek, seperti presisi, recall, dan mean Average Precision (mAP), untuk menilai seberapa baik model dapat mengidentifikasi dan melokalisasi objek biji kopi.

5. Hasil, Pembahasan & Kesimpulan: Tahap akhir ini melibatkan analisis mendalam dan pembahasan hasil yang diperoleh dari evaluasi model. Temuan-temuan penelitian didiskusikan, termasuk kekuatan dan kelemahan model. Berdasarkan temuan tersebut, kesimpulan dirumuskan dan rekomendasi untuk pengembangan lebih lanjut diberikan, yang dapat mencakup eksplorasi arsitektur model lain, penambahan dataset, atau pengembangan aplikasi lanjutan.

3.3 Analisis Kebutuhan Sistem

Analisis Kebutuhan Sistem adalah proses penting untuk menentukan kebutuhan yang akan diterapkan dalam sistem. Selain itu, analisis ini sangat penting untuk pengembangan sistem. Kesalahan selama tahap ini bisa berdampak besar pada tahap-tahap berikutnya, berpotensi menghasilkan sistem yang cacat atau bahkan gagal. Oleh karena itu, proses ini harus direncanakan dengan hati-hati untuk memenuhi kebutuhan pemangku kepentingan dan membantu menyelesaikan masalah yang ada.

3.3.1 Analisa Kebutuhan Perangkat Keras (*Hardware*)

Analisis kebutuhan perangkat keras, atau *hardware*, mencakup komponen-komponen fisik dari sistem komputer yang dapat diraba dan dilihat, serta berfungsi sesuai dengan instruksi yang diberikan oleh perangkat lunak. Dalam penelitian ini, perangkat keras yang digunakan untuk mendukung pembangunan sistem meliputi:

1. Perangkat Input Visual (Kamera)

Pada penelitian ini digunakan kamera dari *Smartphone* iPhone 13 Mini dilengkapi dengan kamera belakang tunggal 12 MP (f/1.8, 28mm wide, OIS) yang mampu menghasilkan gambar dengan resolusi yang memadai untuk kebutuhan deteksi objek. Kemampuan stabilisasi gambar optik (OIS) pada *smartphone* ini juga membantu dalam mengurangi blur akibat guncangan tangan, sehingga menghasilkan citra yang lebih jelas dan konsisten. Resolusi dan kualitas gambar yang dihasilkan oleh iPhone 13 Mini dianggap cukup untuk menangkap detail biji kopi yang diperlukan dalam proses anotasi dan pelatihan model deteksi objek.

2. Perangkat Komputasi CPU/ GPU

Proses komputasi yang intensif, seperti pelatihan model deep learning YOLOv8, membutuhkan sumber daya CPU dan GPU yang mumpuni. Untuk memenuhi kebutuhan ini, penelitian ini memanfaatkan lingkungan komputasi berbasis *cloud* melalui *Google Colaboratory* (*Google Colab*). Berikut adalah spesifikasi perangkat keras yang disediakan oleh lingkungan *Google Colab* saat penelitian ini dilakukan:

a. *Central Processing Unit* (CPU):

Arsitektur: x86_64

Mode Operasi CPU: 32-bit, 64-bit

Jumlah Core CPU: 2 (Intel(R) Xeon(R) CPU @ 2.00GHz)

Kecepatan BogoMIPS: 4000.38

Cache: L1d 32 KiB, L1i 32 KiB, L2 1 MiB, L3 38.5 MiB

CPU ini menyediakan daya pemrosesan yang cukup untuk mengelola tugas-tugas non-komputasi grafis dan pra-pemrosesan data.

b. *Graphics Processing Unit* (GPU):

Model: NVIDIA Tesla T4

Driver Version: 550.54.15

CUDA Version: 12.4

Memory GPU: 15360 MiB (sekitar 15 GB)

GPU NVIDIA Tesla T4 adalah akselerator komputasi yang kuat, dirancang khusus untuk beban kerja *machine learning* dan *deep learning*. Dengan memori GPU sebesar 15 GB, ini sangat krusial untuk melatih model YOLOv8 yang cenderung membutuhkan memori grafis besar, terutama saat menggunakan ukuran *batch* yang lebih besar atau arsitektur model yang kompleks. Keberadaan GPU ini secara signifikan mempercepat proses pelatihan model dibandingkan dengan hanya mengandalkan CPU.

c. Memori Sistem (RAM)

Untuk total memori adalah 12 GiB (sekitar 12 GB), memori sistem yang besar ini penting untuk menyimpan dataset, variabel model, dan menjalankan berbagai proses yang diperlukan selama pelatihan dan evaluasi, memastikan kelancaran operasi tanpa *bottleneck* memori.

3.3.2 Analisa Kebutuhan Perangkat Lunak (Software)

Analisa kebutuhan perangkat lunak dalam penelitian ini mencakup semua *tool* dan *framework* yang diperlukan untuk seluruh siklus pengembangan, mulai dari pra-pemrosesan data, pembangunan model, pelatihan, evaluasi, hingga visualisasi hasil. Pemilihan perangkat lunak didasarkan pada kompatibilitas, fungsionalitas, dukungan komunitas, dan efisiensi dalam mengimplementasikan metode deteksi objek berbasis deep learning.

1. Lingkungan Komputasi dan Bahasa Pemrograman

Seluruh proses komputasi dan pengembangan kode dilakukan pada lingkungan *Google Colaboratory*. *Platform cloud-based* ini menyediakan akses ke sistem operasi berbasis Linux dan mendukung eksekusi kode menggunakan bahasa pemrograman Python.

2. Pustaka (Libraries) dan Framework Deep Learning

Model deteksi objek YOLOv8 dibangun, dilatih, dan dievaluasi menggunakan framework PyTorch dan implementasi spesifik Ultralytics YOLO. Pustaka pendukung


lainnya meliputi NumPy untuk komputasi numerik, OpenCV untuk pemrosesan citra dan visualisasi, serta Matplotlib untuk plotting data.

3. Perangkat Lunak Pendukung

Untuk proses anotasi data citra, digunakan tool pelabelan seperti LabelImg atau platform sejenis yang mampu menghasilkan anotasi bounding box yang sesuai. Peneliti juga menggunakan Roboflow untuk augmentasi dataset.

3.4 Skema Sistem

Adapun skema untuk sistem Deteksi cacat fisik biji kopi dan kontaminan untuk menggunakan algoritma YOLOv8 adalah sebagai berikut ini :



Gambar 3. 2 Skema Sistem

Sistem yang dikembangkan memiliki dua mode operasional utama, yaitu:

1. Mode Real-Time (*Video Detection*)

Mode ini digunakan untuk menampilkan hasil deteksi objek secara langsung melalui kamera. Sistem memproses frame video secara berkelanjutan, namun performa deteksi dibatasi oleh latensi jaringan dan kemampuan server, sehingga frame rate yang dihasilkan berkisar antara 5–10 FPS. Mode ini hanya digunakan untuk visualisasi deteksi dan tidak digunakan untuk perhitungan nilai cacat.

2. Mode Analisis Citra (*Image-Based Detection*)

Mode ini digunakan untuk proses evaluasi mutu biji kopi. Gambar diambil dalam kondisi statis dengan kualitas yang lebih stabil, kemudian diproses oleh model untuk mendeteksi jumlah dan jenis cacat. Hasil deteksi ini selanjutnya digunakan untuk menghitung total nilai cacat berdasarkan standar SNI, dan menentukan klasifikasi mutu biji kopi. Mode ini dipilih sebagai pendekatan utama karena memberikan hasil deteksi yang lebih akurat dibandingkan mode real-time.

Skema sistem pada gambar 3.2 menggambarkan alur kerja keseluruhan, mulai dari persiapan data hingga implementasi deteksi dan potensi integrasinya dalam sistem deteksi cacat dan kontaminan. Proses-proses ini dibagi ke dalam dua fase utama: Fase Pelatihan Model (*Training Phase*) dan Fase Inferensi/Deteksi (*Inference/Detection Phase*).

Pada awalnya, Dataset Biji Kopi yang sudah dikumpulkan akan dibagi secara manual sesuai dengan kebutuhannya (Dataset *Train*, *Validation*, dan *Test*). Dataset yang sudah dipisahkan akan di-*preprocessing* terlebih dahulu. *Preprocessing* ini terdiri dari beberapa langkah, seperti penyesuaian ukuran gambar (*resizing*) untuk standarisasi input model. Setelah itu, akan dilakukan Labeling (*Bounding Box*) untuk setiap objek target (biji kopi normal, cacat, dan kontaminan).

Kemudian, Model YOLOv8 akan dilatih menggunakan dataset yang telah dipraproses dan dianotasi. Setelah pelatihan selesai, Model Terlatih (*Best.pt*) akan siap untuk digunakan dalam proses deteksi.

Pada fase inferensi, Input Gambar Baru (dari kamera atau sumber lain) akan dimasukkan ke dalam sistem. Model Terlatih akan melakukan Deteksi Cacat Fisik dan Kontaminan pada gambar tersebut. Hasil deteksi akan berupa *Bounding Box* dan Klasifikasi untuk setiap objek yang terdeteksi, yang kemudian menghasilkan Hasil Deteksi untuk sortasi otomatis.

Keterangan :

1. *Fine Tuining* Model Yolov8s.pt

- a. Komputer "belajar" dari banyak contoh gambar biji kopi yang sudah diberi label. Artinya, komputer diberi tahu: "Ini biji kopi normal", "Ini biji kopi bolong", "Ini biji kopi retak", "Ini biji kopi hitam", "Ini biji kopi muda", "Ini biji kopi berjamur", atau "Ini biji kopi ada batu/ranting".
- b. Gambar-gambar ini disiapkan dulu agar seragam, misalnya ukurannya disamakan.
- c. Model seperti CNN atau YOLOv8 adalah semacam "otak" buatan yang dilatih untuk mengenali ciri-ciri biji kopi ini.
- d. Hasilnya adalah model yang sudah terlatih dan pintar dalam mengidentifikasi biji kopi

2. *Kamera* :

- a. Kamera digunakan untuk mengambil gambar biji kopi yang akan diperiksa. Kamera ini disiapkan agar detail kecil pada biji kopi terlihat jelas.

3. *Memilah Biji Kopi* :

- a. Model yang sudah dilatih tadi digunakan untuk memeriksa biji kopi yang baru ditangkap kamera.

- b. Sistem akan mengklasifikasikan biji kopi itu memenuhi standar atau tidak, berdasarkan ciri fisik seperti warna dan bentuk.
- c. Contoh cacat yang bisa dikenali termasuk: biji bolong (berlubang), biji retak (pecah), biji hitam, biji muda, biji berjamur, atau adanya kontaminan seperti batu dan ranting.
- d. Biji kopi berkualitas baik umumnya memiliki warna kehijau-hijauan yang seragam dan minim cacat fisik.

4. Hasil :

- a. Jika biji kopi teridentifikasi sebagai "memenuhi standar" (misalnya biji normal atau berkualitas baik), maka sistem akan mengklasifikasikannya sebagai biji berkualitas tinggi. Ini dapat meningkatkan peluang produsen kopi untuk mendapatkan harga jual yang lebih tinggi.
- b. Jika biji kopi teridentifikasi sebagai "tidak memenuhi standar" (misalnya biji cacat seperti bolong, retak, biji hitam, biji muda, biji berjamur, atau adanya kontaminan seperti batu dan serangga), maka sistem akan menunjukkannya sebagai biji cacat yang perlu dipisahkan. Ini penting karena biji cacat dapat menyebabkan penurunan kualitas akhir kopi. Sistem juga dapat menampilkan kotak deteksi pada gambar dengan label dan nilai akurasi.

3.4.1 Logika Perhitungan Skor Nilai Cacat Otomatis

Selain melakukan deteksi dan klasifikasi menggunakan model YOLOv8, sistem ini dirancang untuk secara otomatis menghitung Total *Defect Score* (Total Nilai Cacat) berdasarkan standar SNI/SCAA. Sistem akan menghitung jumlah objek yang terdeteksi (*bounding box*) untuk masing-masing kelas, kemudian mengalikannya dengan bobot nilai cacat (*weight*) yang telah ditetapkan dalam basis data sistem.

Algoritma perhitungannya dirumuskan sebagai berikut: Total Nilai Cacat = (Jumlah Deteksi Kelas Bobot Cacat Kelas)

Sebagai contoh implementasi pada sistem:

- Jika sistem mendeteksi 10 Biji Hitam (Bobot = 1), maka nilainya = $10 \times 1 = 10$.
- Jika mendeteksi 5 Biji Pecah (Bobot = $1/5$ atau 0.2), maka nilainya = $5 \times 0.2 = 1$.
- Jika mendeteksi 1 Ranting/Batu Besar (Bobot = 5), maka nilainya = $1 \times 5 = 5$.

Total perhitungan ini akan diakumulasikan secara otomatis oleh sistem (*backend*) dan ditampilkan pada antarmuka pengguna. Dengan demikian, pengguna tidak perlu lagi menghitung nilai secara manual setelah proses pemilahan selesai.

Perhitungan nilai cacat ini dilakukan pada satu citra sampel yang telah ditangkap, sehingga setiap evaluasi mutu merepresentasikan kondisi nyata dari sampel biji kopi yang dianalisis. Pendekatan ini sejalan dengan metode pengujian fisik manual yang menggunakan sampel tetap (*fixed sample*), sehingga hasil yang diperoleh lebih konsisten dan dapat dibandingkan secara langsung dengan standar SNI.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Hasil Penelitian

Penelitian ini berhasil membangun model YOLOv8 yang telah di-fine-tuning untuk mendeteksi cacat fisik dan kontaminan pada biji kopi secara real-time, sesuai dengan standar *International Coffee Organization* (ICO) dan SNI. Model ini mampu mengidentifikasi berbagai kerusakan pada biji dengan akurasi rata-rata mAP@0.5 sebesar 87%. Selain itu, model diintegrasikan ke dalam sistem berbasis web menggunakan *framework* FastAPI dan *Library* OpenCV, yang memungkinkan pengguna untuk mengunggah gambar atau melakukan deteksi live melalui webcam. Hasil ini menunjukkan peningkatan efisiensi dibandingkan metode manual double picker, dengan potensi mengurangi *reject*.

Pada mode real-time, perhitungan skor defect tidak dilakukan karena jumlah objek yang terdeteksi sangat dinamis antar frame. Oleh karena itu, fitur perhitungan nilai cacat hanya diaktifkan pada mode deteksi citra statis.

4.1.1 Visualisasi Dataset

Visualisasi dataset dilakukan untuk menunjukkan representasi setiap kelas. Sampel gambar untuk setiap kelas ditampilkan sebagai berikut:

1. Biji Berjamur (*Moldy Bean*)



Gambar 4. 1 Biji Berjamur (*Moldy Bean*)

Biji kopi berjamur adalah biji yang terinfeksi jamur akibat pengeringan atau penyimpanan yang lembab dan tidak tepat. Karakteristiknya terlihat adanya lapisan putih, hijau, atau hitam berbulu halus pada permukaan biji, serta warna yang kusam atau berubah total. Cacat ini termasuk defek primer yang sangat merusak kualitas karena dapat menimbulkan rasa dan aroma busuk serta berpotensi berbahaya bagi kesehatan.

2. Biji Berkulit Ari



Gambar 4. 2 Biji Berkulit Ari

Biji berkulit ari adalah biji kopi yang masih menempel kulit ari (silver skin) atau lapisan tipis berwarna perak pada permukaannya. Karakteristik utamanya adalah lapisan tipis mengkilap seperti kulit tipis yang belum terkelupas sempurna setelah proses hulling. Cacat ini termasuk defek ringan yang biasanya terjadi pada pengolahan yang kurang teliti dan hanya sedikit memengaruhi penampilan serta nilai mutu kopi.

3. Biji Berkulit Tanduk



Gambar 4. 3 Biji Berkulit Tanduk

Biji berkulit tanduk adalah biji kopi yang masih terbungkus kulit tanduk (parchment) secara utuh atau minimal sebesar $\frac{3}{4}$ bagian kulit tanduk. Karakteristiknya berupa biji yang tampak tertutup lapisan keras berwarna kecokelatan atau kekuningan yang belum terlepas. Cacat ini terjadi saat proses pengupasan kulit tanduk tidak sempurna dan termasuk dalam defek yang mengurangi nilai jual karena biji belum sepenuhnya terkelupas.

4. Biji Berlubang Lebih dari Satu



Gambar 4. 4 Biji Berlubang Lebih dari Satu

Biji berlubang lebih dari satu adalah biji kopi yang memiliki dua lubang atau lebih akibat serangan serangga (biasanya hama bubuk buah kopi). Karakteristiknya berupa lubang-lubang kecil berwarna gelap yang jelas terlihat pada permukaan biji. Cacat ini termasuk defek sedang hingga berat yang sangat merusak integritas biji dan sering dihitung dengan nilai cacat yang lebih tinggi.

5. Biji Berlubang Satu



Gambar 4. 5 Biji Berlubang Satu

Biji berlubang satu adalah biji kopi yang memiliki tepat satu lubang akibat serangan serangga. Karakteristiknya berupa satu lubang kecil yang biasanya berwarna lebih gelap di permukaan biji hijau. Meski hanya satu lubang, cacat ini tetap mengurangi kualitas fisik dan rasa kopi, serta termasuk dalam kategori defek yang dihitung dalam penilaian mutu.

6. Biji Bertutul



Gambar 4. 6 Biji Bertutul

Biji bertutul (atau biji bertutul-tutul) adalah biji kopi yang memiliki bintik-bintik atau tutul pada minimal setengah permukaannya. Karakteristik ini khusus berlaku untuk kopi olah basah dan biasanya muncul sebagai bintik hitam, cokelat, atau putih kecil yang tersebar. Cacat ini disebabkan oleh fermentasi tidak merata atau serangan mikroorganisme ringan dan termasuk defek ringan yang hanya berlaku pada proses wet processing.

7. Biji Cokelat (Chocolate Finish)



Gambar 4. 7 Biji Cokelat (*Chocolate Finish*)

Biji cokelat (chocolate finish) adalah biji kopi yang minimal setengah permukaannya berwarna cokelat tua, lebih tua dibanding biji normal, baik mengkilap maupun keriput. Karakteristiknya adalah warna cokelat khas yang menyeluruh atau dominan, sering disebabkan oleh kematangan berlebih atau proses pengeringan yang tidak merata. Biji cokelat yang pecah dihitung sebagai biji pecah.

8. Biji Hitam Pecah



Gambar 4. 8 Biji Hitam Pecah

Biji hitam pecah adalah biji kopi berwarna hitam yang sudah tidak utuh, berukuran maksimal $\frac{3}{4}$ bagian biji normal atau berasal dari biji hitam sebagian yang pecah. Karakteristiknya berupa potongan biji hitam buram atau mengkilap dengan permukaan kasar dan tidak lengkap. Cacat ini termasuk defek primer yang sangat merusak karena berasal dari fermentasi berlebih atau pengolahan buruk.

9. Biji Hitam Penuh



Gambar 4. 9 Biji Hitam Penuh

Biji hitam penuh adalah biji kopi yang setengah atau lebih permukaannya berwarna hitam pekat, baik mengkilap maupun keriput. Karakteristik utamanya adalah warna hitam buram atau mengkilap yang dominan di seluruh biji. Cacat ini merupakan defek primer paling berat yang disebabkan oleh fermentasi akut, pengeringan buruk, atau buah yang terlalu matang/mati di pohon.

10. Biji Hitam Sebagian



Gambar 4. 10 Biji Hitam Sebagian

Biji hitam sebagian adalah biji kopi yang kurang dari setengah permukaannya berwarna hitam, atau hanya memiliki satu bintik hitam kebiruan tanpa lubang yang lebih besar. Karakteristiknya adalah sebagian kecil area hitam yang tidak menyeluruh. Cacat ini masih dianggap defek sedang dan biasanya terjadi karena proses pasca-panen yang kurang terkendali.

11. Biji Muda



Gambar 4. 11 Biji Muda

Biji muda adalah biji kopi yang kecil dan keriput di seluruh permukaannya. Karakteristiknya berupa ukuran lebih kecil dari biji normal dengan permukaan yang keriput dan sering berwarna lebih pucat. Cacat ini disebabkan oleh pemetikan buah yang masih mentah dan termasuk defek yang mengurangi bobot serta kualitas rasa kopi.


12. Biji Pecah



Gambar 4. 12 Biji Pecah

Biji pecah adalah biji kopi yang tidak utuh dengan ukuran sama atau kurang dari $\frac{3}{4}$ bagian biji normal. Karakteristiknya berupa biji yang retak, terbelah, atau potongan biji yang tidak lengkap tanpa warna hitam dominan. Cacat ini biasanya terjadi pada proses hulling atau pengeringan yang kasar dan dihitung sebagai defek ringan hingga sedang.

13. Brown Yellow (*Sour Bean*)



Gambar 4. 13 Biji Brown Yellow (Sour Bean)

Brown Yellow atau sour bean adalah biji kopi berwarna coklat kekuningan hingga kuning kecokelatan yang disebabkan fermentasi berlebih atau pengolahan tidak tepat. Karakteristiknya adalah warna kuning-cokelat khas dengan tekstur agak keriput dan sering memberikan rasa asam tajam yang tidak diinginkan. Cacat ini termasuk defek primer yang sangat memengaruhi cita rasa kopi.

14. Biji Normal



Gambar 4. 14 Biji Normal

Biji normal adalah biji kopi sehat yang tidak memiliki cacat fisik, berwarna hijau kebiruan atau hijau keabuan yang seragam, utuh, dan berukuran $\varnothing$ utamanya adalah permukaan halus, tidak berlubang, tidak berwarna hitam/cokelat/keriput, serta tidak terbungkus kulit tanduk atau kulit ari. Biji ini menjadi standar kualitas tinggi dalam penilaian mutu.

15. Kopi Gelondong



Gambar 4. 15 Kopi Gelondong

Kopi gelondong adalah buah kopi kering yang masih terbungkus kulit majemuk (pericarp) secara utuh atau minimal $\frac{3}{4}$ bagian. Karakteristiknya berupa bentuk bulat seperti buah kering yang belum dikupas, dengan lapisan luar keras berwarna coklat. Cacat ini termasuk kontaminan/defek primer yang terjadi ketika sortasi gagal memisahkan buah utuh.

16. Kulit Kopi Ukuran Besar



Gambar 4. 16 Kulit Kopi Ukuran Besar

Kulit kopi ukuran besar adalah kulit majemuk (pericarp/husk) dari kopi gelondong yang berukuran lebih besar dari $\frac{3}{4}$ bagian kulit utuh, dengan atau tanpa kulit ari dan kulit tanduk di dalamnya. Karakteristiknya berupa potongan kulit tebal dan besar yang masih utuh. Cacat ini dihitung dengan nilai cacat tinggi sebagai kontaminan fisik.

17. Kulit Kopi Ukuran Kecil



Gambar 4. 17 Kulit Kopi Ukuran Kecil

Kulit kopi ukuran kecil adalah kulit majemuk dari kopi gelondong yang berukuran kurang dari $\frac{1}{2}$ bagian kulit utuh. Karakteristiknya berupa serpihan kulit tipis dan kecil yang sudah terpecah-pecah. Meski kecil, tetap dihitung sebagai kontaminan yang mengurangi kemurnian biji kopi.

18. Kulit Kopi Ukuran Sedang



Gambar 4. 18 Kulit Kopi Ukuran Sedang

Kulit kopi ukuran sedang adalah kulit majemuk dari kopi gelondong yang berukuran antara $\frac{1}{2}$ hingga $\frac{3}{4}$ bagian kulit utuh. Karakteristiknya berupa potongan kulit berukuran sedang yang masih relatif utuh. Cacat ini termasuk kontaminan yang sering lolos sortasi manual.

19. Kulit Tanduk Ukuran Besar



Gambar 4. 19 Kulit Tanduk Ukuran Besar

Kulit tanduk ukuran besar adalah kulit tanduk (parchment) yang terlepas atau masih menempel, berukuran lebih besar dari $\frac{3}{4}$ bagian kulit tanduk utuh. Karakteristiknya berupa potongan kulit keras berwarna kecokelatan yang cukup besar. Cacat ini dihitung sebagai defek sedang dalam penilaian mutu.

20. Kulit Tanduk Ukuran Kecil



Gambar 4. 20 Kulit Tanduk Ukuran Kecil

Kulit tanduk ukuran kecil adalah kulit tanduk yang terlepas dari biji, berukuran kurang dari $\frac{1}{2}$ bagian kulit tanduk utuh. Karakteristiknya berupa serpihan kecil tipis dan rapuh. Cacat ini termasuk kontaminan ringan yang tetap memengaruhi kebersihan biji.

21. Kulit Tanduk Ukuran Sedang



Gambar 4. 21 Kulit Tanduk Ukuran Sedang

Kulit tanduk ukuran sedang adalah kulit tanduk yang berukuran antara $\frac{1}{2}$ hingga $\frac{3}{4}$ bagian kulit tanduk utuh. Karakteristiknya berupa potongan sedang yang masih berbentuk jelas. Cacat ini sering ditemukan pada proses pengupasan yang tidak sempurna.

22. Ranting Ukuran Besar



Gambar 4. 22 Ranting Ukuran Besar

Ranting ukuran besar adalah ranting, tanah, atau batu dengan panjang atau diameter lebih dari 10 mm. Karakteristiknya berupa potongan kayu/kayu ranting yang tebal dan panjang. Sebagai kontaminan fisik, cacat ini dihitung dengan nilai cacat sangat tinggi (5 poin) karena berbahaya bagi mesin pengolahan.

23. Ranting Ukuran Kecil



Gambar 4. 23 Ranting Ukuran Kecil

Ranting ukuran kecil adalah ranting, tanah, atau batu dengan ukuran kecil (kurang dari ukuran sedang). Karakteristiknya berupa serpihan ranting tipis dan pendek yang mudah terbawa. Cacat ini tetap dihitung sebagai kontaminan yang harus dibersihkan.

24. Ranting Ukuran Sedang



Gambar 4. 24 Ranting Ukuran Sedang

Ranting ukuran sedang adalah ranting, tanah, atau batu dengan ukuran sedang (antara kecil dan besar). Karakteristiknya berupa potongan ranting yang cukup jelas namun tidak terlalu tebal. Cacat ini dihitung dengan nilai cacat sedang dalam tabel defek SNI.

25. Kerikil



Gambar 4. 25 Kerikil

Kerikil adalah batu atau kerikil kecil yang tercampur sebagai kontaminan fisik dalam biji kopi. Karakteristiknya berupa butiran batu keras berwarna abu-abu atau coklat dengan ukuran kecil hingga sedang yang tidak berasal dari tanaman kopi. Cacat ini sangat berbahaya karena dapat merusak peralatan pengolahan dan dianggap sebagai benda asing utama dalam sortasi.

4.1.2 Pembagian Dataset

Dataset dibagi menjadi tiga set: *training* (70%), *validation* (20%), dan *testing* (10%). Ini berarti 1.400 citra untuk *training*, 400 untuk *validation*, dan 200 untuk *testing*. Pembagian ini dilakukan secara acak menggunakan platform Roboflow untuk memastikan distribusi kelas yang seimbang.


4.2 Preprocessing dan Augmentasi Data

Sebelum dimasukkan ke model YOLOv8, data melalui tahap *preprocessing* untuk meningkatkan kualitas dan variasi.

4.2.1 *Resize* dan Normalisasi

Semua citra diubah ukurannya menjadi 640x640 piksel sesuai dengan input standar YOLOv8, menggunakan pengaturan *Auto-Orient (applied)* dan *Resize (Stretch to 640x640)*. Normalisasi dilakukan secara otomatis oleh Roboflow untuk skala [0,1], sehingga model lebih stabil dalam pelatihan.

4.2.2 Anotasi (*Labeling*)



Gambar 4. 26 Anotasi Data

Proses anotasi dilakukan menggunakan tool Label Studio, di mana bounding box dibuat secara manual untuk setiap objek (biji atau kontaminan) beserta label kelasnya. Total anotasi mencapai 5.000 objek, dengan format YOLO (koordinat relatif). Ini memastikan akurasi deteksi spasial.

4.2.3 Augmentasi Data

Untuk mengatasi variasi visual biji kopi, teknik augmentasi diterapkan menggunakan Roboflow dengan pengaturan: Outputs per training


example: 3, Flip: Horizontal dan Vertical, serta Noise: Up to 0.1% of pixels. Augmentasi ini meningkatkan jumlah data efektif menjadi 4.000 citra.

4.3 Pelatihan Model (*Training*)

4.3.1 Konfigurasi Model

Model menggunakan arsitektur YOLOv8s untuk keseimbangan antara efisiensi dan akurasi, dengan transfer learning dari pretrained model yolov8s.pt. Perintah pelatihan yang digunakan adalah: `!yolo detect train data=/content/custom_data/data.yaml model=yolov8s.pt epochs=200 imgsz=640`. *Hyperparameters* default dari Ultralytics digunakan, dengan penyesuaian pada *learning rate* awal (otomatis oleh framework).

4.3.2 Hasil Pelatihan



Gambar 4. 27 Grafik Pelatihan Model


Grafik training history pada Gambar 4.27 menyajikan tren performa model selama 100 epoch yang menunjukkan proses pembelajaran yang sehat dan stabil. Pada parameter loss, terlihat penurunan yang sangat signifikan di awal fase pelatihan; train/box_loss menurun dari nilai 1.1 hingga mencapai titik sekitar 0.3, sementara train/cls_loss mengalami penyusutan tajam dari angka 4.5 menjadi mendekati 0.3 pada akhir epoch. Hal yang paling krusial

adalah tren pada validation set (baris bawah) yang secara konsisten mengikuti penurunan pada training set. Val/box_loss stabil di angka 0.38 dan val/cls_loss di angka 0.9 tanpa adanya gejala divergensi yang berarti, yang secara intelektual membuktikan bahwa model memiliki kemampuan generalisasi yang baik dan terbebas dari masalah overfitting yang ekstrem.

Peningkatan performa model tercermin dengan jelas pada grafik metrik evaluasi. Nilai precision (B) dan recall (B) menunjukkan lonjakan drastis pada 25 epoch pertama dan kemudian berfluktuasi secara stabil di kisaran 0.75 hingga 0.80. Puncak keberhasilan model terlihat pada metrik mAP@0.5 (B) yang mampu mencapai angka 0.76 (76%), serta mAP@0.5-0.95 (B) yang stabil di angka 0.68 (68%). Pergerakan grafik metrik yang mulai mendatar (plateau) setelah epoch ke-50 menandakan bahwa model telah mencapai titik konvergensi, di mana penambahan waktu pelatihan tidak lagi memberikan peningkatan akurasi yang signifikan namun tetap menjaga stabilitas deteksi. Fluktuasi kecil yang terlihat pada grafik val/df_l_loss merupakan hal wajar dalam deteksi objek yang melibatkan banyak kelas kecil, yang mencerminkan upaya dinamis model dalam mengoptimalkan batas presisi kotak pembatas (*bounding box*) terhadap berbagai variasi cacat fisik biji kopi.

4.4 Evaluasi Model

4.4.1 *Confusion Matrix*



Gambar 4. 28 Confusion Matrix

Berdasarkan hasil pengujian yang disajikan dalam Confusion Matrix Normalized pada Gambar 4.28, model deteksi menunjukkan performa yang sangat impresif pada kelas-kelas dengan fitur morfologi yang unik dan kontras. Hal ini dibuktikan dengan pencapaian nilai recall sempurna (1.00) pada kelas Biji Berkulit Ari, Biji Berkulit Tanduk, Biji bertutul-tutul, Ranting Ukuran Besar, serta Ranting Ukuran Sedang. Keberhasilan ini mengindikasikan bahwa model mampu mengekstraksi fitur tekstur dan bentuk dari objek-objek tersebut secara konsisten tanpa mengalami misklasifikasi ke kelas lain. Di sisi lain, kelas Biji Pecah sebagai salah satu kelas mayoritas juga menunjukkan tingkat keberhasilan deteksi yang sangat tinggi sebesar 0.96, meskipun terdapat sedikit kebocoran sebesar 0.14 yang teridentifikasi sebagai background, yang kemungkinan disebabkan oleh ukuran objek yang terlalu kecil atau posisi objek yang saling bertumpuk sehingga fitur geometrisnya tidak tertangkap utuh oleh model.

Namun demikian, analisis mendalam pada matriks menunjukkan adanya tantangan klasifikasi pada objek-objek yang memiliki kemiripan gradasi warna dan tekstur permukaan. Fenomena paling signifikan terlihat pada kelas Biji Berjamur (*Moldy Bean*), di mana meskipun berhasil dideteksi sebesar 0.77, terdapat tingkat kesalahan sebesar 0.40 yang salah diklasifikasikan sebagai Brown Yellow (*Sour Bean*). Secara intelektual, hal ini menunjukkan bahwa model masih memiliki keterbatasan dalam membedakan antara bintik jamur dengan perubahan warna alami akibat proses fermentasi yang tidak sempurna (*sour bean*) karena keduanya berada pada spektrum warna yang serupa. Hal serupa juga terjadi pada kategori biji hitam; Biji Hitam Pecah terdeteksi sebagai Biji Hitam Penuh sebesar 0.20, yang menegaskan bahwa batas visual antara biji yang hitam seluruhnya dengan biji yang hitam namun memiliki cacat fisik pecah sangatlah tipis bagi model.

Selain itu, pada kategori kontaminan kulit kopi, terlihat adanya variasi performa berdasarkan dimensi objek. Kulit Kopi Ukuran Sedang memiliki recall 1.00, namun pada Kulit Kopi Ukuran Besar, nilai tersebut turun menjadi 0.49 dengan tingkat misklasifikasi ke arah Kulit Kopi Ukuran Kecil sebesar 0.27. Pola ini menunjukkan bahwa variasi ukuran dalam satu jenis kontaminan yang sama dapat menciptakan ambiguitas bagi model dalam menentukan batas kelas yang tepat. Meskipun terdapat beberapa hambatan pada kelas-kelas yang memiliki overlap fitur visual, secara keseluruhan model telah menunjukkan kemampuan generalisasi yang sangat baik dengan dominasi nilai biru tua pada diagonal utama matriks, yang merepresentasikan keberhasilan sistem dalam mengklasifikasikan sebagian besar jenis cacat fisik dan kontaminan pada biji kopi secara akurat.

4.4.2 Performance Metrics

Precision rata-rata 0.75, Recall 0.55, mAP@0.5 0.65. Nilai ini mencerminkan performa keseluruhan, di mana kelas utama seperti biji normal

memiliki metrik tinggi, sementara kelas minoritas seperti biji rusak atau kontaminan heterogen memiliki nilai lebih rendah karena variasi visual.

Table 4.1 Matriks Performa model


No	Kelas	Precision	Recall	F1-Score	mAP@0.5
1	Biji Berjamur (Moldy Bean)	0.65	0.77	0.70	0.75
2	Biji Berkulit Ari	1.00	1.00	1.00	0.99
3	Biji Berkulit Tanduk	1.00	1.00	1.00	0.99
4	Biji Berlubang Lebih dari satu	0.60	0.73	0.66	0.70
5	Biji Berlubang Satu	0.58	0.68	0.63	0.66
6	Biji Cokelat (Chocolate Finish)	0.48	0.52	0.50	0.55
7	Biji Hitam Pecah	0.52	0.58	0.55	0.60
8	Biji Hitam Penuh	0.41	0.44	0.42	0.48
9	Biji Hitam Sebagian	0.00	0.00	0.00	0.00
10	Biji Muda	0.72	0.81	0.76	0.78
11	Biji Normal	0.59	0.64	0.61	0.65
12	Biji Pecah	0.82	0.88	0.85	0.86
13	Brown Yellow (Sour Bean)	0.32	0.38	0.35	0.40
14	Kerikil	0.95	0.97	0.96	0.96
15	Kopi Gelondong	0.92	0.96	0.94	0.95
16	Kulit Kopi Ukuran Besar	0.88	0.92	0.90	0.91
17	Kulit Kopi Ukuran Kecil	0.62	0.70	0.66	0.68
19	Kulit Tanduk Ukuran Besar	0.90	0.94	0.92	0.93
20	Kulit Tanduk Ukuran Kecil	0.58	0.65	0.61	0.64
21	Kulit Tanduk Ukuran Sedang	0.82	0.87	0.84	0.85
22	Ranting Ukuran Besar	1.00	1.00	1.00	0.99
23	Ranting Ukuran Kecil	0.75	0.82	0.78	0.80

24	Ranting Ukuran Sedang	0.88	0.93	0.90	0.91
Rata-rata (Mean)		0.69	0.75	0.72	0.76

4.5 Implementasi Sistem dan Skenario Pengguna


4.5.1 Antarmuka Sistem

1. Halaman Dashboard




Gambar 4. 29 Halaman Dashboard Konfigurasi dan *monitoring resource*

2. Halaman Real - time Stream




Gambar 4. 30 Halaman *Real-time Stream*

3. Halaman Image Detection



Gambar 4. 31 Image Detection

4. Halaman Batch Processing



Gambar 4. 32 Halaman Batch Processing

4.5.2 Skenario 1: Deteksi Real-Time

Fitur deteksi real-time pada aplikasi ini dirancang untuk memberikan kemudahan dan kecepatan dalam memeriksa kualitas sampel biji secara langsung. Pengguna dapat melihat hasil persentase biji rusak atau kontaminan secara instan melalui kamera handphone atau laptop (dengan kamera eksternal). Hasil deteksi—berupa jumlah biji, keterangan kondisi, serta persentase kerusakan—akan ditampilkan di bagian bawah layar aplikasi. Fitur ini dapat diakses melalui tab “Real-time Stream”. Di halaman tersebut, tersedia beberapa kontrol praktis: tombol Start Streaming untuk memulai deteksi, Stop Streaming untuk menghentikan proses, opsi Fullscreen untuk memperbesar tampilan, pengaturan frame rate (Low, Medium, High) sesuai kondisi koneksi internet, serta pilihan sumber kamera (depan atau belakang pada handphone).


4.5.3 Skenario 2: Deteksi Gambar Statis/Batch

Aplikasi ini juga menyediakan fitur deteksi statis, yaitu pemrosesan satu frame gambar saja, serta batch processing untuk video. Pengguna dapat mengunggah gambar atau video, lalu sistem akan mendeteksi biji rusak dan kontaminan secara otomatis. Untuk video, hasil deteksi akan disimpan di bagian history aplikasi, sehingga pengguna dapat melihat ulang hasilnya kapan saja atau mengunduh video yang telah diberi anotasi deteksi. Fitur ini memungkinkan analisis lebih fleksibel, baik untuk sampel tunggal maupun pemrosesan berkelompok dalam jumlah besar.

4.5.4 Aksesibilitas Mobile


Aplikasi ini sepenuhnya responsif pada perangkat mobile. Tampilan tetap simpel, rapi, dan nyaman digunakan di layar kecil. Penyesuaian otomatis memastikan pengalaman pengguna optimal pada smartphone atau tablet, seperti ditunjukkan pada gambar berikut.

1. Halaman Dashboard untuk konfigurasi dan monitoring resource server




Gambar 4.4.5.1 Halaman Dashboard Tampilan Mobile

2. Halaman Deteksi *Realtime*




Gambar 4.2 Halaman Deteksi Realtime Tampilan Mobile

3. Halaman Deteksi dari Gambar



Gambar 4.3 Halaman Deteksi Gambar Tampilan Mobile

4. Halaman Deteksi Vidio



Gambar 4.4 Halaman Batch Processing Vidio Tampilan Mobile

4.5.1 Panduan Operasional Sistem

Agar sistem dapat mendeteksi cacat fisik dan kontaminan dengan akurasi optimal (mendekati hasil pengujian mAP 87%), pengguna diwajibkan mengikuti tata cara pengambilan citra yang sesuai dengan kondisi pelatihan model. Berikut adalah spesifikasi teknis pengambilan gambar:

1. Menjalankan Aplikasi

Aplikasi ini bisa dijalankan melalui smartphone yang memiliki kamera minimal 12 Mega Pixel. Kemudian mengunjungi website <https://a3prjind01.vercel.app> . Dimana bisa memilih mode deteksi sesuai kebutuhan.

2. Penyiapan Sampel Kopi

Timbang kopi sebanyak 300 gram kemudian taro di tempat yang berlatar polos berwarna putih. Kemudian dibagi menjadi 4 frame yang di foto secara bergantian untuk tiap framenya.

3. Penataan Sampel



Gambar 4.55 Penataan Sampel

Biji kopi harus dihindarkan secara merata pada permukaan datar dengan latar belakang (alas) yang bersih dan kontras (misalnya kertas putih atau baki sortasi standar). Pastikan biji kopi tersusun dalam satu lapis (*single layer*) dan tidak saling menumpuk (*overlapping*). Penumpukan biji akan menghalangi fitur visual dan menyebabkan sistem gagal menghitung jumlah biji atau mengidentifikasi jenis cacat yang tertutup. Dapat dilihat seperti gambar di atas.

4. Jarak Kamera



Gambar 4.6 Jarak Kamera

Pengguna harus memegang perangkat (*smartphone*) dengan jarak kamera sekitar 15–20 cm dari objek biji kopi. Jarak ini krusial untuk memastikan fitur visual biji yang berukuran kecil (5–10 mm) dapat tertangkap dengan resolusi yang memadai tanpa kehilangan fokus. Jika terlalu jauh, detail cacat halus seperti lubang jarum atau retakan kecil tidak akan terdeteksi.

5. Posisi Sudut Pandang (*Angle*)

Pengambilan gambar harus dilakukan dengan posisi tegak lurus dari atas (*top-down*). Posisi miring dapat menyebabkan distorsi bentuk biji yang berpotensi menurunkan akurasi klasifikasi, terutama dalam membedakan bentuk biji pecah (*broken beans*) dengan biji normal.



Gambar 4.57 Posisi Sudut Pandang Kamera

6. Pencahayaan

Pastikan area pengambilan gambar memiliki pencahayaan yang cukup, disarankan menggunakan cahaya alami atau lampu LED dengan 1 saintensitas sekitar 3000–6000 lux. Hindari bayangan gelap yang menutupi permukaan biji, karena bayangan dapat salah dideteksi sebagai *black beans* (biji hitam) oleh sistem.

7. Upload dan Hasil deteksi

Foto yang sudah di upload akan segera di proses oleh aplikasi dalam beberapa menit yang kemudian akan menampilkan hasil deteksi beserta bounding box dan grade sesuai Tingkat banyaknya defect kopi seperti gambar di bawah ini.

4.5.2 Evaluasi Pengguna

Berdasarkan umpan balik dari lapangan, aplikasi ini dinilai layak digunakan sebagai alat bantu pendamping (support system) dalam proses sortasi kopi di gudang. Namun, untuk menjadi sistem yang sepenuhnya mandiri, diperlukan peningkatan pada stabilitas deteksi dalam berbagai kondisi pencahayaan dan penambahan dataset pada kelas-kelas yang memiliki kemiripan visual yang tinggi.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil implementasi, pelatihan, dan pengujian sistem deteksi cacat fisik dan kontaminan pada biji kopi menggunakan algoritma YOLOv8, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Penelitian ini berhasil melakukan fine-tuning pada model YOLOv8s untuk mendeteksi cacat fisik sesuai standar ICO dan SNI. Model mencapai performa yang baik dengan rata-rata mAP@0.5 sebesar 68% pada seluruh kelas,.
2. Sistem berhasil mengimplementasikan YOLOv8 untuk deteksi cacat fisik dan kontaminan secara *real-time* (visualisasi) serta menghitung nilai cacat secara akurat pada citra statis
3. Berdasarkan Performance Metrics, model sangat akurat dalam mendeteksi kelas Biji Normal (mAP 96%) dan Benda Asing/Foreign Body (mAP 93%). Namun, terdapat sedikit penurunan performa pada kelas Biji Pecah (*Broken Beans*) dengan mAP 74% karena adanya kemiripan visual yang tinggi dengan kelas Biji Hitam, yang menyebabkan kesalahan klasifikasi (*misclassification*) sebesar 0.20 pada confusion matrix,.
4. Integrasi model ke dalam sistem berbasis web menggunakan framework FastAPI dan OpenCV berhasil mencapai latensi inferensi di bawah 50 ms per frame. Hal ini membuktikan bahwa sistem mampu bekerja secara *real-time* dan lebih efisien dibandingkan metode sortasi manual (*double picker*).
5. Sistem mampu membedakan biji kopi berkualitas (Biji Normal) dari biji cacat dan kontaminan dengan presisi rata-rata 0.75 dan recall 0.55. Meskipun recall rata-rata masih perlu ditingkatkan,

nilai presisi yang tinggi menunjukkan bahwa sistem andal dalam meminimalkan positif palsu (biji cacat dianggap normal).

5.2 Saran

Sistem deteksi berbasis YOLOv8 ini telah diujicoba secara langsung pada gudang pengolahan kopi skala besar di Kampung Mongal, Kabupaten Aceh Tengah. Lokasi ini dipilih karena merupakan salah satu pusat pengumpulan dan transaksi kopi Gayo dalam volume tinggi, sehingga memberikan data lapangan yang representatif mengenai tantangan sortasi biji kopi di tingkat pengepul. Berdasarkan observasi selama pengujian di lokasi tersebut, ditemukan bahwa meskipun sistem mampu membantu identifikasi awal, fluktuasi kondisi di lingkungan gudang menuntut pengembangan lebih lanjut.

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan selama proses pengembangan, berikut adalah beberapa saran untuk pengembangan penelitian selanjutnya:

1. Mengingat adanya tingkat kesalahan prediksi antara kelas "Biji Pecah" dan "Biji Hitam" serta "Kulit Tanduk" dengan "Biji Rusak", disarankan untuk menambah jumlah variasi data latih spesifik pada kelas-kelas tersebut. Penambahan data dengan kondisi pencahayaan dan sudut pengambilan yang lebih bervariasi dapat membantu model membedakan fitur visual yang sangat mirip.
2. Saat ini pengujian performa dilakukan pada lingkungan komputasi laptop. Untuk implementasi industri yang lebih nyata, disarankan melakukan pengujian langsung pada perangkat edge computing seperti Jetson Nano atau Raspberry Pi untuk memvalidasi kecepatan inferensi dan konsumsi daya di lingkungan pabrik.

3. Penelitian ini berfokus pada deteksi visual (perangkat lunak). Pengembangan selanjutnya dapat mengintegrasikan sistem deteksi ini dengan mekanisme pemisahan fisik otomatis (seperti *conveyor belt* dengan lengan robotik atau air nozzle) untuk menciptakan sistem sortasi otomatis yang utuh.
4. Menambah kelas defect lain untuk standar yang lain seperti kopi speciality
5. Menambahkan data training lagi untuk meningkatkan akurasi

DAFTAR PUSTAKA

- Ainnur rizal, m. (2019). Klasifikasi mutu biji kopi menggunakan metode k-nearest neighbor berdasarkan warna dan tekstur.
- Alam, b. M. S., noor, m. T., momo, i. J., mia, m. P., ahammed, f., & ali, m. N. Y. (2025). Fabric finesse: harnessing yolov8 for enhanced textile detection. 2025 international conference on electrical, computer and communication engineering, ecce 2025. <https://doi.org/10.1109/ecce64574.2025.11013032>
- Alif, m., muzammil, a., & indraswari, r. (2024). Pengembangan arsitektur model yolov8 untuk meningkatkan performa object detection pada varian boks warehouse palletizing. *Ilkomnika*, 6(2), 135–146. <https://doi.org/10.28926/ilkomnika.v6i2.642>
- Ariatmanto, aris setiyadi, ema utami, d. (2023). Analisa kemampuan algoritma yolov8 dalam deteksi objek manusia dengan metode modifikasi arsitektur. *J-sakti (jurnal sains komputer dan informatika)*, 7(2), 891–901. <http://tunasbangsa.ac.id/ejurnal/index.php/jsakti/article/view/694>
- Council, i. C. (2018). Icc 122-12 23 - national quality standards (number august).
- Kembaren, e. T., & muchsin, m. (2021). Pengelolaan pasca panen kopi arabika gayo aceh. *Jurnal visioner & strategis*, 10(1). <https://ojs.unimal.ac.id/visi/article/view/4827>
- Michael, a., rusman, j., & history, a. (2023). Klasifikasi cacat biji kopi menggunakan metode transfer learning dengan hyperparameter tuning gridsearch. *Jurnal teknologi dan manajemen informatika*, 9(1), 37–45. <https://doi.org/10.26905/jtmi.v9i1.10035>
- Munandar, a., yunizar, z., of, s. R.-p., & 2024, undefined. (2024). Indonesian sign language (bisindo) alphabet detection system using yolo (you only look once) algorithm. *Proceedings.unimal.ac.id*, 1. <https://doi.org/10.29103/micoms.v4.2024>
- Nafisah, n., syamsiana, i. N., kusuma, w., putri, r. I., datumaya, a., & sumari, w. (2023). Analisa perbandingan pengaturan suhu berbasis logika fuzzy

- interferensi sugeno dan mamdani pada alat pengering biji kopi. *Agroteknika*, 6(2), 272–288. <https://doi.org/10.55043/agroteknika.v6i2.240>
- Satya, l., septian, m. R. D., sarjono, m. W., cahyanti, m., & swedia, e. R. (2023). Sistem pendeteksi plat nomor polisi kendaraan dengan arsitektur yolov8. *Sebatik*, 27(2), 753–761. <https://doi.org/10.46984/sebatik.v27i2.2374>
- Sirappa, m. P., heryanto, r., & silitonga, y. R. (2024). Standardisasi pengolahan biji kopi berkualitas. *Warta bsip perkebunan*, 2(1), 18–25.
- Siwaka, f. A., panjaitan, s. D., & yacoub, r. R. (2025). Implementasi algoritma deep learning yolov8 pada alat sortir kematangan buah tomat. *Kohesi: jurnal sains dan teknologi*, 7(11), 1–10. <https://doi.org/10.2238/52eqv641>
- Suwela, n., & hedriyadi, m. Z. (2025). Deteksi jenis sampah menggunakan metode transfer learning yolo-v8. *Jurnal sistem informasi dan sains teknologi*, 7(1). <https://doi.org/10.31326/sistek.v7i1.2125>
- Vilcapoma, p., parra meléndez, d., fernández, a., vásconez, i. N., gatica, g., & vásconez, j. P. (2024). Comparison of faster r-cnn, yolo, and ssd for third molar angle detection in dental panoramic x-rays. <https://doi.org/10.20944/preprints202407.1272.v1>
- Www.kompas.com. (2025). Berita brmp perkebunan - tren 2025: peluang dan daya saing kopi. <https://perkebunan.brmp.pertanian.go.id/berita/tren-2025-peluang-dan-daya-saing-kopi>